Klasteryzacja

Zaimplementowałem klasteryzację hierarchiczną, metodą k-średnich oraz spektralną.

Na początku nie stosowałem algorytmu Lance'a Williamsa przez co klastrowanie hierarchiczne trwało bardzo długo. Po zastosowaniu go przyśpieszyło drastycznie (z $1min\ 26s$ do około $1.2s$ na zbiorze `rp.data`).

Klasyfikatory oparte na klastrowaniu sprawdzały się dobrze na pliku `rp.data`. Nie stosowałem funkcji jądrowych. Wyniki dla liczby klastrów równej liczbie cech są przedstawione tutaj.

Następnie spróbowałem dla każdego datasetu (poza `2D_5` bo jest ich dużo więc obliczenia byłyby długie) dobrać optymalną liczbę klastrów.

Narysowałem wykresy błędu zdefiniowanego na slajdzie z KMeans w zależności od liczby klastrów i użyłem na tym reguły łokcia.

Oto uzyskane wykresy:

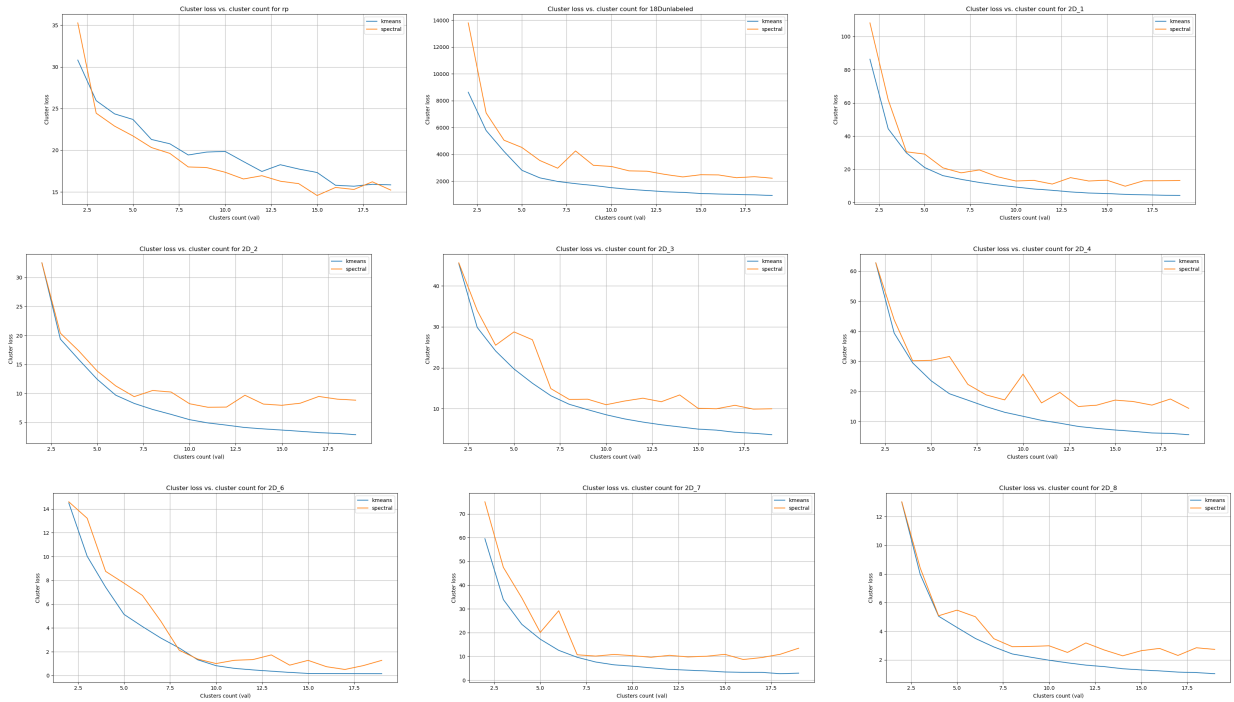

Nie sprawdzałem błędów dla klastrowania hierarchicznego bo było istotnie wolniejsze od alternatyw.

Na podstawie tych wykresów wyznaczyłem liczby klastrów dla każdego z plików `dane_2D_i.txt`.

Po uruchomieniu modeli na danych dwuwymiarowych z liczbą klastrów równą $2 * \textit{liczba różnych etykiet}$ oraz z dobraną przeze mnie liczbą klastrów otrzymałem podobne lub trochę lepsze wyniki na liczbach dobranych przez siebie. Wyjątkiem jest dataset `data2D_6` gdzie dobrałem mniej klastrów niż jest cech (10 zamiast 15) i precyzja spadła z 99% do 66%.

Z wyników można wywnioskować, że klastrowanie za pomocą łączenia pojedynczego (min-linking) generalnie sprawdza się gorzej od innych rodzajów klastrowania ale są datasety (`dane2D_4.txt`) których specyfika sprawia, że działa ono zdecydowanie lepiej od innych.

Można też zauważyć, że klastrowanie spektralne daje gorsze wyniki od hierarchicznego oraz kmeans ale jest szybsze na małych danych.

Poniżej zamieszczam 2 wizualizacje przedstawiające działanie zaimplementowanych algorytmów klasteryzacji na dwuwymiarowych danych. Pierwsza przedstawia klastry rozróżnione na drodze klastrowania a druga przypisanie

Tabela 1: Classification Accuracy per Model and Dataset

dataset	hclusterer	hclusterer-avg-linking	hclusterer-min-linking	kmeans	spectral
2D-1	0.9962	0.9962	0.8274	0.9810	0.8934
2D-2	0.9323	0.9273	0.7845	0.8972	0.8371
2D-3	0.9800	0.9767	0.8233	0.8867	0.9100
2D-4	0.4904	0.5513	1.0000	0.4936	0.5641
2D-5	0.9387	0.9381	0.2652	0.9429	0.4555
2D-6	0.6667	0.6667	0.6000	0.6667	0.6667
2D-7	1.0000	1.0000	1.0000	1.0000	0.9142
2D-8	0.9917	1.0000	0.6750	0.9917	0.9667
rp	0.9678	0.9429	0.6515	0.9707	0.9634

Tabela 2: Training times per Model and Dataset in seconds

dataset	hclusterer	hclusterer-avg-linking	hclusterer-min-linking	kmeans	spectral
2D-1	1.6886	2.3283	2.1427	0.3779	0.6421
2D-2	0.3145	0.4821	0.4261	0.2377	0.1496
2D-3	0.1720	0.2670	0.2461	0.2340	0.0856
2D-4	0.1936	0.2882	0.2531	0.2091	0.0950
2D-5	111.6594	118.4379	118.6860	3.8827	12.6481
2D-6	0.8240	1.1859	1.0700	0.2258	0.3378
2D-7	0.2696	0.4175	0.3658	0.2388	0.1258
2D-8	0.1144	0.1761	0.1615	0.2068	0.0536
rp	1.2320	1.7865	1.6064	0.0648	0.4976

etykiet do punktów.

Dataset 2D_1

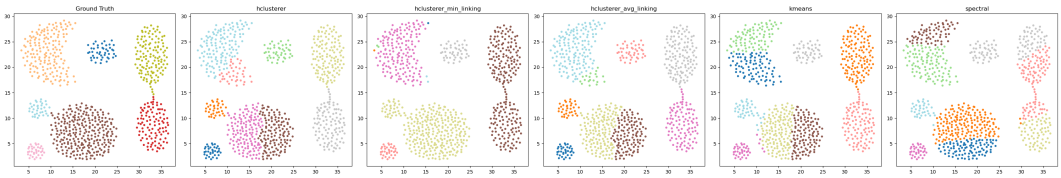

All clusters 1: Dataset `2D_1`

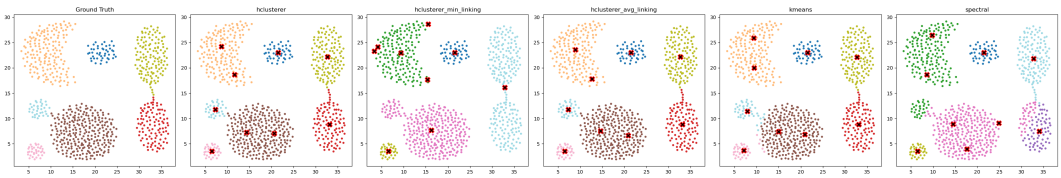

Classification results 2: Dataset `2D_1`

Dataset 2D_2

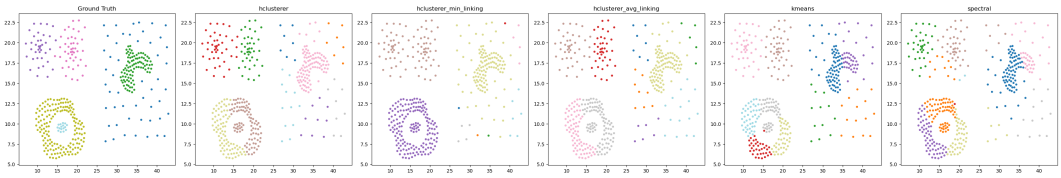

All clusters 3: Dataset 2D_2

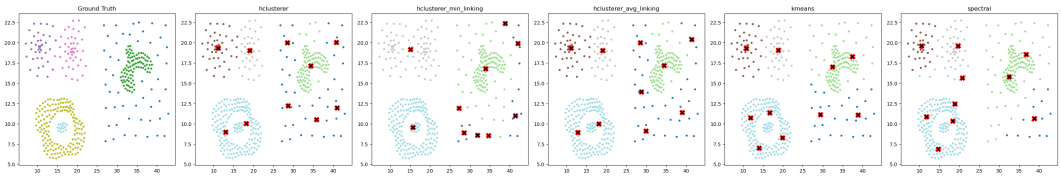

Classification results 4: Dataset 2D_2

Dataset 2D_3

All clusters 5: Dataset 2D_3

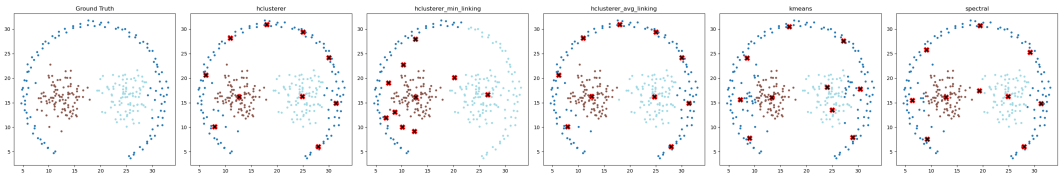

Classification results 6: Dataset 2D_3

Dataset 2D_4

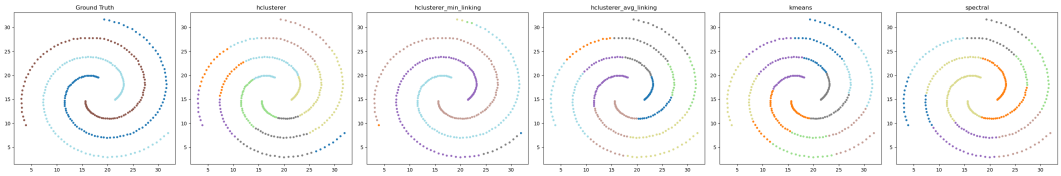

All clusters 7: Dataset 2D_4

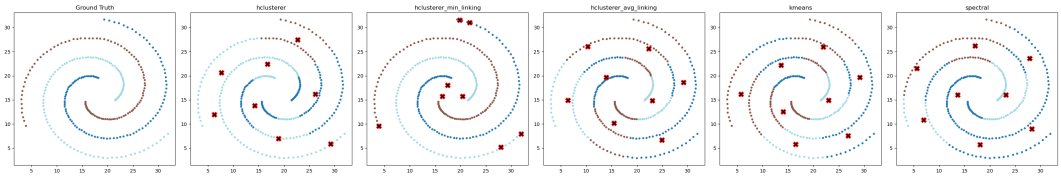

Classification results 8: Dataset 2D_4

Dataset 2D_5

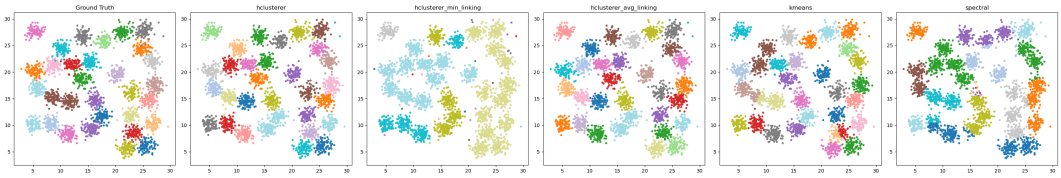

All clusters 9: Dataset 2D_5

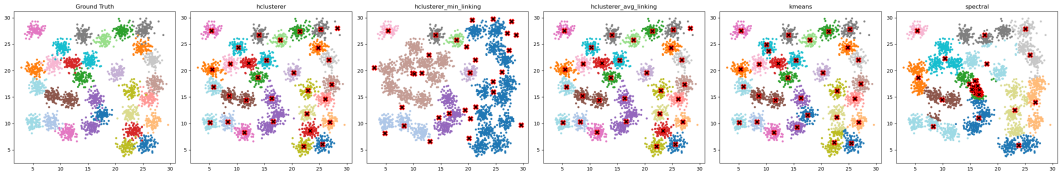

Classification results 10: Dataset 2D_5

Dataset 2D_6

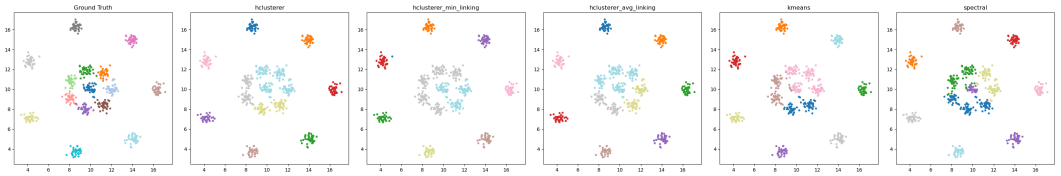

All clusters 11: Dataset 2D_6

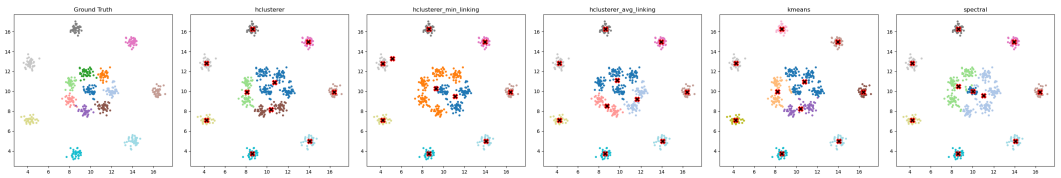

Classification results 12: Dataset 2D_6

Dataset 2D_7

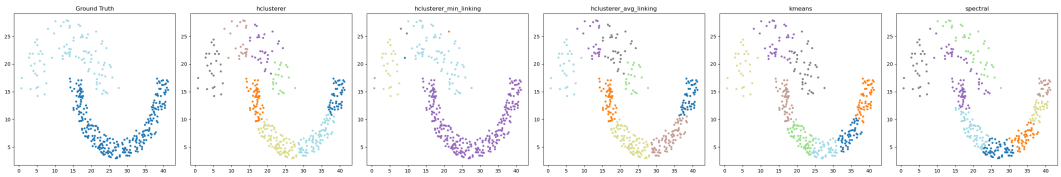

All clusters 13: Dataset 2D_7

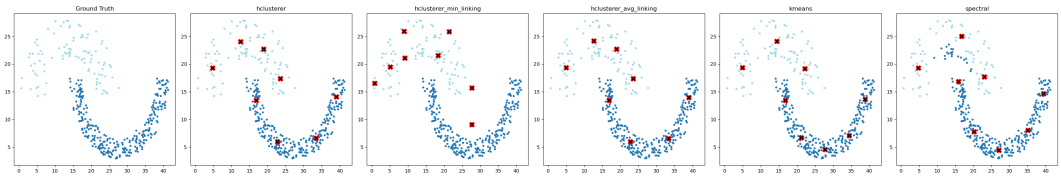

Classification results 14: Dataset 2D_7

Dataset 2D_8

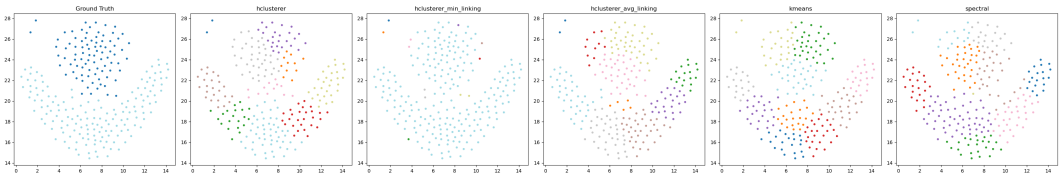

All clusters 15: Dataset 2D_8

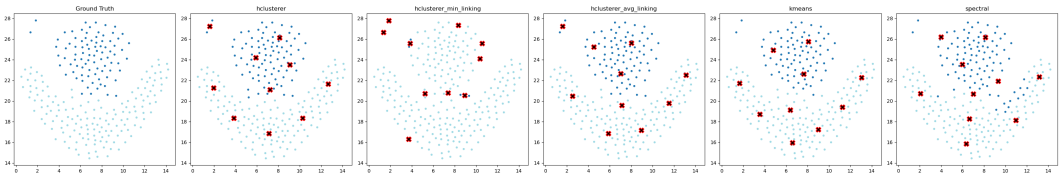

Classification results 16: Dataset 2D_8